

TED Skills

AWS Glue e PySpark




PAOLA ZANETTI - 1102518

OBIETTIVI

L'app TedSkills deve generare un Portfolio delle competenze in base ai talk visti. Come fa il sistema a sapere quale competenza assegna un video?

Invece di far calcolare le categorie all'applicazione in tempo reale, usiamo **AWS Glue** per analizzare il campo tags e pre-calcolare una categoria (es. *Leadership, Sostenibilità*) inserendola direttamente nello schema JSON su MongoDB



INTEGRAZIONE WATCH NEXT

```
86  tedx_dataset_agg.printSchema()
87
88  #Read related video dataset
89  watch_next_dataset_path = "s3://tedx-2026-data-pz/related_videos.csv"
90  watch_next_dataset = spark.read.option("header","true").csv(watch_next_dataset_path)
91
92  #Create the aggregate model without duplicate
93  watch_next_dataset_agg = watch_next_dataset.groupBy(col("id").alias("id_ref")) \
94  | .agg(collect_set("related_id").alias("watch_next"))
95
96  # Join with the main table
97  tedx_dataset_agg = tedx_dataset_agg.join(watch_next_dataset_agg, tedx_dataset_agg._id == watch_next_dataset_agg.id_ref, "left") \
98  | .drop("id_ref")
99
100 tedx_dataset_agg.printSchema()
101
102
103 write_mongo_options = {
104     "connectionName": "TedxLab",
105     "database": "unibg_tedx_2026",
```

Fase di extract

Fase di transform

evitare duplicati

Join

[Codice su github](#)

RISULTATO

```
_id: "567505"
slug: "ben_proudfoot_the_true_story_of_the_iconic_tagline_because_i_m_worth_i_"
speakers: "Ben Proudfoot"
title: "The true story of the iconic tagline "Because I'm worth it." | The Fin..."
url: "https://www.ted.com/talks/ben_proudfoot_the_true_story_of_the_iconic_t..."
description: "From two-time Oscar winner Ben Proudfoot comes THE FINAL COPY OF ILON ..."
duration: "1059"
publishedAt: "2025-03-07T13:49:56Z"
tags: Array (8)
  0: "culture"
  1: "media"
  2: "social change"
  3: "marketing"
  4: "communication"
  5: "film"
  6: "women"
  7: "feminism"
```

```
_id: "567505"
slug: "ben_proudfoot_the_true_story_of_the_iconic_tagline_because_i_m_worth_i_"
speakers: "Ben Proudfoot"
title: "The true story of the iconic tagline "Because I'm worth it." | The Fin..."
url: "https://www.ted.com/talks/ben_proudfoot_the_true_story_of_the_iconic_t..."
description: "From two-time Oscar winner Ben Proudfoot comes THE FINAL COPY OF ILON ..."
duration: "1059"
publishedAt: "2025-03-07T13:49:56Z"
tags: Array (8)
  0: "culture"
  1: "media"
  2: "social change"
  3: "marketing"
  4: "communication"
  5: "film"
  6: "women"
  7: "feminism"
watch_next: Array (3)
  0: "87043"
  1: "88795"
  2: "121643"
```

Il database MongoDB è stato aggiornato: ora il documento principale del TED Talk include direttamente l'array "watch_next".

CLASSIFICATORE DI SOFT SKILLS

```
100 #Assign the soft skill - like if elif else
101 tedx_dataset_agg = tedx_dataset_agg.withColumn(
102     "soft_skill",
103     when(
104         array_contains(col("tags"), "business") |
105         array_contains(col("tags"), "work"),
106         "Leadership"
107     )
108     .when(
109         array_contains(col("tags"), "environment") |
110         array_contains(col("tags"), "nature"),
111         "Sostenibilità"
112     )
113     .when(
114         array_contains(col("tags"), "communication") |
115         array_contains(col("tags"), "society"),
116         "Empatia/Relazione"
117     )
118     # Space for other category
119     .otherwise("Competenza Trasversale Generica")
120 )
121
```

Per rispondere all'obiettivo di TEDSkills, il codice trasforma i dati grezzi in competenze: ricerca parole chiave specifiche all'interno dei tag e calcola in automatico la macro-categoria della Soft Skill da mostrare nel Portfolio

[Codice su github](#)

RISULTATO

Da dato grezzo a
informazione di valore:
ogni TED Talk possiede
ora il campo soft_skill
necessario per il
Portfolio

```
_id: "566059"
slug: "y_vonne_hutchinson_where_dei_falls_short_and_how_to_rethink_it"
speakers: "Y-Vonne Hutchinson"
title: "Where DEI falls short – and how to rethink it"
url: "https://www.ted.com/talks/y_vonne_hutchinson_where_dei_falls_short_and..."
description: "Tired of “privilege walks” and black squares on social media that feel..."
duration: "341"
publishedAt: "2025-02-28T15:40:45Z"
tags: Array (6)
  0: "culture"
  1: "business"
  2: "work"
  3: "society"
  4: "diversity"
  5: "inclusion"
watch_next: Array (6)
  0: "132052"
  1: "1074"
  2: "1113"
  3: "131495"
  4: "674"
  5: "127050"
soft_skill: "Leadership"
```

CRITICITÀ TECNICHE

- **Dati duplicati:** nel file sorgente molti ID dei video consigliati erano duplicati per uno stesso talk. La criticità è stata risolta utilizzando la funzione `collect_set` (invece di `collect_list`) durante la fase di transform
- **Rigidità della classificazione basata sui tag:** l'attuale logica di assegnazione delle soft skills è basata su regole fisse e si può verificare che la prima condizione vera blocchi l'assegnazione. Se un TED Talk è multidisciplinare il sistema lo categorizzerà in automatico solo nella prima skill incontrata nel codice.

EVOLUZIONI

- **Estrazione delle soft skills tramite AI:** invece di basarsi su regole fisse sui tag, si potrebbe implementare un modello basato su AI in modo che non si analizzi solo i tag, ma l'intera descrizione testuale del video, deducendo in modo molto più preciso le competenze.
- **Automazione della pipeline:** attualmente il job di AWS Glue deve essere avviato manualmente. L'evoluzione dell'architettura prevede l'inserimento di una funzione AWS Lambda.
- **Raccomandazioni dinamiche per il PCTO:** al momento i video watch next sono statici. Il sistema non suggerirebbe più video generici, ma video specifici per colmare le lacune nel Portfolio dello studente.